

Análisis Predictivo de la Calidad del Vino Tinto

Modelos de Ensamble y Optimización

Regina Tamayo | Valeria Milke | Elisa Aguirre

Ingeniería Financiera

OBJETIVOS DEL PROYECTO

Objetivo General

Desarrollar y comparar modelos de aprendizaje automático (**Random Forest y XGBoost**) para clasificar la calidad del vino tinto, optimizando su rendimiento mediante búsqueda de hiperparámetros y validación cruzada.

Objetivos Específicos

- Realizar un **análisis exploratorio (EDA)** de las características del dataset WineQT.
- Implementar un **pipeline de preprocesamiento** para la limpieza y normalización de datos.
- Aplicar **optimización (Random Search)** para hallar los mejores hiperparámetros.
- Evaluar el desempeño mediante **Accuracy y k-folds cross-validation** para asegurar estabilidad.
- Interpretar resultados para concluir sobre la viabilidad del modelo en  **producción vinícola**.

MARCO TEÓRICO

Regresión Lineal

Método estadístico que modela la relación entre una variable dependiente y una o más independientes mediante una línea recta.

$$y \quad Y = \beta_0 + \beta_1 X_1 + \epsilon$$

Ensamble de Modelos

Estrategia que combina múltiples algoritmos "débiles" para crear un predictor fuerte.

- **Bagging:** Votos en paralelo (Random Forest).
- **Boosting:** Aprendizaje secuencial (XGBoost).

Quimiometría

Es la aplicación de métodos matemáticos y estadísticos a datos químicos. En este proyecto, traduce la composición molecular en una métrica de calidad percibida.

ANÁLISIS DEL DATASET WINEQT

Origen

Publicado por el ingeniero M. Yasser, especialista en AI & ML

Dimensiones y Tipos

- **Muestras:** 1,143 filas.
- **Columnas:** 13 (11 features químicos, Id, Target).
- **Features:** Alcohol, pH, Sulfatos, Acidez, Cloruros (Numéricos).

Distribución de Clases

Target: Quality (3 a 8)

Desbalance Crítico: Calidades 5 y 6 representan el 83% de los datos. Las clases 3 y 8 son inferiores al 2%.

PIPELINE DEL PROYECTO



MODELOS PROPUESTOS



Random Forest

Efectivo contra el ruido y excelente para capturar relaciones no lineales sin sobreajustar.



XGBoost

Potencia el rendimiento mediante gradientes, optimizado para precisión extrema en clases difíciles.

HIPERPARÁMETROS OPTIMIZADOS

Algoritmo	Hiperparámetro	Rango / Valores
Random Forest	n_estimators	100, 200, 300, 500
	max_depth	None, 10, 20, 30
	min_samples_split	2, 5, 10
	criterion	'gini', 'entropy'
XGBoost	n_estimators	100, 200, 300
	learning_rate	0.01, 0.05, 0.1, 0.2
	subsample	0.7, 0.8, 0.9

RESULTADOS (K-FOLDS CROSS VALIDATION)



Métrica Elegida: Accuracy.

El Random Forest superó ligeramente al XGBoost en precisión media.

INTERPRETACIÓN DE HALLAZGOS

Éxito en Intermedios

F1-score de **0.77** y **0.67** para calidades 5 y 6. El modelo identifica con gran éxito los vinos promedio debido al alto volumen de ejemplos.

Falla en Extremos

Las calidades 3 y 8 tuvieron un **F1 de 0.00**. El desbalance de datos impide que el modelo aprenda patrones de vinos defectuosos o premium.

CONCLUSIONES

- ✓ **Cumplimiento de Objetivos:** Se logró un Accuracy del 69% en el set de prueba, cumpliendo la meta de estabilidad.
- ✓ **Modelo Ganador:** Random Forest demostró ser más robusto ante el ruido fisicoquímico del dataset WineQT.
- ✓ **Viabilidad:** Es una herramienta útil para estandarizar la producción de vinos comerciales masivos.

REFERENCIAS (APA)

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5-32.

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *SIGKDD Conference*.

Cortez, P., et al. (2009). Modeling wine preferences by physicochemical properties from data mining. *Decision Support Systems*.

Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*.

Yasser, H. (2022). *Wine Quality Dataset*. Kaggle. <https://www.kaggle.com/datasets/yasserh/wine-quality-dataset>